

Willgnner Ferreira Santos

**Classificação de Petições Jurídicas com Modelos  
Ajustados via BERT: Uma Alternativa à  
Plataforma BERNÁ**

Goiânia-GO

2025

Willgnner Ferreira Santos

# **Classificação de Petições Jurídicas com Modelos Ajustados via BERT: Uma Alternativa à Plataforma BERNÁ**

Projeto final apresentado ao curso de Residência em TI, como requisito para aprovação na disciplina Introdução à Programação.

Universidade Federal de Goiás - Regional Goiânia

Orientadora: Prof. Dra. Nádia Félix Felipe da Silva

Goiânia-GO

2025

# Lista de ilustrações

Figura 1 – <i>Front-end</i> do projeto . . . . .	12
--	----

# Lista de tabelas

Tabela 1 – Resultados da avaliação do modelo no conjunto de teste . . . . .	11
---	----

# Lista de abreviaturas e siglas

IA	Inteligência Artificial
TJGO	Tribunal de Justiça do Estado de Goiás
BERNA	Busca Eletrônica Recursiva usando Linguagem Natural
PLN	Processamento de Linguagem Natural
BERT	Bidirecional Encoder Representations from Transformers

# Sumário

	<b>INTRODUÇÃO</b>	<b>6</b>
	<b>OBJETIVO</b>	<b>7</b>
	<b>PÚBLICO-ALVO</b>	<b>8</b>
	<b>DESCRIÇÃO DO BANCO DE DADOS/ARQUIVO</b>	<b>9</b>
	<b>DESCRIÇÃO DA SOLUÇÃO</b>	<b>10</b>
<b>0.1</b>	<b>Preparação dos Dados</b>	<b>10</b>
<b>0.2</b>	<b>Tokenização e Pré-processamento</b>	<b>10</b>
<b>0.3</b>	<b>Configuração do Modelo</b>	<b>10</b>
<b>0.4</b>	<b>Configuração do Treinamento</b>	<b>11</b>
<b>0.5</b>	<b>Avaliação</b>	<b>11</b>
<b>0.6</b>	<b>Resultados</b>	<b>11</b>
<b>0.7</b>	<b>Link para Aplicação com Código Fonte</b>	<b>12</b>
	<b>REFERÊNCIAS</b>	<b>13</b>

# INTRODUÇÃO

Nos últimos anos, o Poder Judiciário brasileiro (MENDES, 2016) tem buscado aplicar métodos de Inteligência Artificial (IA) para lidar com o crescimento exponencial do volume processual (BASHILOV; BERMAN, 2022). Nesse contexto, o Tribunal de Justiça do Estado de Goiás (TJGO) desenvolveu a **BERNA (Busca Eletrônica Recursiva usando Linguagem Natural)** (CAMPOS, 2022), uma solução baseada em Processamento de Linguagem Natural (PLN) (BARBOSA et al., 2017) voltada para o apoio à análise e organização de petições iniciais. Inicialmente, a BERNNA operava com técnicas supervisionadas para identificação de precedentes, evoluindo depois para métodos não supervisionados, combinando redes neurais artificiais (RAUBER, 2005) e estratégias de agrupamento por similaridade textual (FONSECA et al., 2016).

A ferramenta é capaz de identificar padrões recorrentes em petições, agrupando ações semelhantes a partir da detecção de fatos e teses jurídicas. Também realiza tarefas como juntada automática de documentos, análise preliminar de processos e habilitação de procuradores, promovendo uma automação parcial do fluxo processual.

Este trabalho propõe uma alternativa baseada em modelos ajustados via fine-tuning de redes Bidirecional Encoder Representations from Transformers (BERT) (KOROTEEV, 2021), com o objetivo de classificar as petições em três categorias, sendo **fatos**, **teses** e **ruído**, com maior precisão. A motivação é avaliar se, com melhor desempenho, esse modelo pode substituir ou complementar a solução BERNNA no processo de triagem e análise automática de documentos jurídicos.

# OBJETIVO

Avaliar o desempenho de um modelo baseado em BERT, ajustado com dados reais de petições jurídicas, para classificar trechos textuais em três classes:  **fatos**, **teses** e **ruídos**. O trabalho busca verificar se a acurácia do modelo permite substituir, ou ao menos complementar, as funcionalidades da ferramenta BERNÁ no contexto de automação do fluxo processual.



## PÚBLICO-ALVO

Pesquisadores, profissionais e estudantes das áreas de Ciência da Computação, Direito e Engenharia de Dados, com interesse em aplicações de IA em textos jurídicos. A solução também é voltada para magistrados, desembargadores e demais servidores do Poder Judiciário, aqueles também que atuam na triagem, análise e processamento de petições iniciais. O objetivo é fornecer uma ferramenta técnica que possa ser utilizada de forma prática e integrada às rotinas do Tribunal de Justiça, contribuindo para a automação e otimização do fluxo processual.

# DESCRIÇÃO DO BANCO DE DADOS/ARQUIVO

Para o treinamento e validação do modelo, foi utilizada uma base composta por 26.781 trechos extraídos de petições judiciais reais do acervo processual do TJGO. Cada trecho foi previamente classificado em uma das três categorias: **fato (descrição dos eventos do caso)**, **tese (fundamentação legal e argumentação do autor ou réu)** e **ruído (informações irrelevantes, duplicadas ou fora de escopo)**. O conjunto de dados foi construído de maneira equilibrada, com **8.927** exemplos para cada classe, assegurando uma distribuição igualitária entre os rótulos.

Para o treinamento, foram utilizados **21.424 trechos (aproximadamente 80% da base)**, enquanto os **5.357 trechos restantes foram reservados para o teste (aproximadamente 20%)**. Ambos os subconjuntos mantiveram a proporcionalidade original entre as classes, com **7.142 instâncias de cada classe no treino e 1.785 ou 1.786 instâncias por classe no teste**, garantindo assim a homogeneidade e a representatividade dos dados em todas as etapas do processo.

O *dataset* foi preparado com atenção à diversidade temática e textual, o que visa promover maior robustez ao modelo diante da variedade de estilos linguísticos e estruturas argumentativas encontradas em documentos judiciais.

# DESCRIÇÃO DA SOLUÇÃO

A solução proposta consiste na adaptação de um modelo pré-treinado baseado na arquitetura BERT, ajustado com fine-tuning para a tarefa de classificação de trechos de petições jurídicas em três categorias: **fato**, **tese** e **ruído** textual. O objetivo é automatizar a triagem e rotulação de partes relevantes dos documentos jurídicos, oferecendo uma alternativa às funcionalidades atualmente desempenhadas pela ferramenta BERNA.

## 0.1 Preparação dos Dados

O conjunto de dados utilizado foi previamente separado com rótulos correspondentes às três classes mencionadas. Após o carregamento do *dataset* em formato `.csv`, foi aplicada uma amostragem aleatória de 50% dos registros, com o intuito de reduzir o tempo de treinamento sem comprometer a diversidade de exemplos. Os dados foram então divididos em conjuntos de treino (80%) e teste (20%), mantendo a proporção das classes por meio de estratificação.

Esses conjuntos foram convertidos para a estrutura **DatasetDict**, da biblioteca *datasets* da **Hugging Face**, permitindo integração direta com os modelos e ferramentas de NLP disponíveis na plataforma.

## 0.2 Tokenização e Pré-processamento

Foi utilizado o modelo `nlpaueb/legal-bert-base-uncased`, especializado em linguagem jurídica. O tokenizador correspondente foi aplicado a todos os textos, com truncamento para o limite máximo de 512 tokens. Para padronizar os lotes de entrada durante o treinamento, foi utilizado o `DataCollatorWithPadding`, garantindo alinhamento nos tamanhos de sequência.

## 0.3 Configuração do Modelo

O modelo `AutoModelForSequenceClassification` foi carregado com o número de rótulos ajustado para três classes. Também foram definidos os mapeamentos `id2label` e `label2id` para facilitar a interpretação dos resultados e a configuração do modelo.

## 0.4 Configuração do Treinamento

O treinamento do modelo foi realizado utilizando a classe `Trainer`, da biblioteca `transformers`, com os seguintes hiperparâmetros:

1. **Taxa de aprendizado:**  $2 \times 10^{-5}$
2. **Número de épocas:** 10
3. **Tamanho do *batch* (*batch size*):** 8
4. **Avaliação e salvamento:** realizados ao final de cada época
5. **Critério para seleção do melhor modelo:** acurácia
6. ***Callback* de *early stopping*:** interrompe o treinamento se não houver melhora por 2 épocas consecutivas

Esses parâmetros foram escolhidos com base em boas práticas para *fine-tuning* de modelos BERT, equilibrando desempenho e custo computacional.

## 0.5 Avaliação

Após o treinamento, o modelo foi avaliado com base nas previsões feitas sobre o conjunto de teste. As métricas utilizadas foram acurácia e relatório de classificação (`classification_report`), extraídas com as bibliotecas `evaluate` e `scikit-learn`.

A acurácia foi obtida a partir da comparação direta entre os rótulos previstos e os rótulos reais. Além disso, foram analisadas métricas específicas por classe (**precisão**, **recall** e ***F1-score***), possibilitando avaliar o desempenho do modelo em distinguir entre trechos descritivos (**fatos**), (**teses**) e trechos irrelevantes (**ruído**).

## 0.6 Resultados

Tabela 1 – Resultados da avaliação do modelo no conjunto de teste

Classe	Precisão	<i>Recall</i>	<i>F1-score</i>
FATO	0.97	0.96	0.97
TESE	0.96	0.97	0.97
RUÍDO	1.00	1.00	1.00
<b>Acurácia</b>	0.9772		
<b>Média Macro</b>	0.98	0.98	0.98
<b>Média Ponderada</b>	0.98	0.98	0.98

Os resultados na Tabela 1 obtidos no conjunto de teste indicam que o modelo ajustado com base no **Legal-BERT** apresentou desempenho elevado na tarefa de classificação de trechos jurídicos. A acurácia global foi de **97.72%**, com valores de precisão, *recall* e *F1-score* superiores a *0.96* para todas as classes. A classe "**RUIDO**" atingiu métricas ótimas (**1.00**), enquanto "**FATO**" e "**TESE**" também apresentaram desempenho consistente e equilibrado. As médias macro e ponderada confirmam a estabilidade do modelo mesmo em presença de possíveis desequilíbrios nas classes.

A interface do projeto foi desenvolvida utilizando a biblioteca **Streamlit**, ilustrada na 1 que permite a criação de aplicações *web* de forma rápida e interativa com **Python**. O *front-end* oferece uma área para inserção de petições jurídicas e apresenta os resultados da classificação de forma visual, destacando os trechos classificados como fato, tese ou ruído. O objetivo é tornar a ferramenta acessível a usuários não técnicos, como magistrados e servidores, facilitando o uso do modelo treinado diretamente no navegador.

Figura 1 – *Front-end* do projeto



## 0.7 Link para Aplicação com Código Fonte

<https://github.com/Willgnner-Santos/IT-Residence.git>

# Referências

- BARBOSA, J. et al. Introdução ao processamento de linguagem natural usando python. *III Escola Regional de Informatica do Piauí*, v. 1, p. 336–360, 2017. Citado na página 6.
- BASHILOV, B. I.; BERMAN, A. M. Procedural documents in the era of new technologies: how legal design has changed the legal world. *New Technology for Inclusive and Sustainable Growth: Technological Support, Standards and Commercial Turnover*, Springer, p. 261–270, 2022. Citado na página 6.
- CAMPOS, M. S. O uso da inteligência artificial no poder judiciário: as contribuições do sistema berna para o tribunal de justiça de goiás. Pontifícia Universidade Católica de Goiás, 2022. Citado na página 6.
- FONSECA, E. et al. Assin: Avaliacao de similaridade semantica e inferencia textual. In: *Computational Processing of the Portuguese Language-12th International Conference, Tomar, Portugal*. [S.l.: s.n.], 2016. p. 13–15. Citado na página 6.
- KOROTEEV, M. V. Bert: a review of applications in natural language processing and understanding. *arXiv preprint arXiv:2103.11943*, 2021. Citado na página 6.
- MENDES, G. Organização do poder judiciário brasileiro. 2016. Citado na página 6.
- RAUBER, T. W. Redes neurais artificiais. *Universidade Federal do Espírito Santo*, v. 29, p. 39, 2005. Citado na página 6.